




量子 × 投資組合最佳化研究

QUBO & Annealing for Portfolio Optimization



以 QUBO 形式求解 GMVP / MSRP，並在 0050 成分股上進行 5 季 walk-forward 樣本外比較

金融四雙應數-溫亮達

研究簡報 台股 0050 · LSTM 預測 · QUBO · D-Wave Ocean 模擬退火 · 2025/03–2026/03



簡報大綱

Agenda

從量子退火原理出發，建立 MSRP / GMVP 的 QUBO 模型，並在 5 季 walk-forward 回測中，與古典凸最佳化及多個基準公平比較。



01

量子退火演算法

退火、能量基態與量子穿隧



02

退火的超參數

sweeps · reads · penalty · 精度



03

現代投資組合理論與效率前緣

Markowitz 均值-變異數框架



04

MSRP 與 GMVP

最大夏普 vs 最小變異投組



05

MSRP / GMVP → QUBO

離散化編碼、預算懲罰與稠密耦合



06

研究設計：0050、LSTM 與共變異數

walk-forward · 防洩漏 · 五種 Σ



07

實證結果

解品質 · penalty · 樣本外 · beta 拆解



	買他以後未來一季預期賺n% (預期報酬)	未來一季報酬率的波動度(標準差)	
股票A	10%	5%	
股票B	15%	10%	
股票C	20%	20%	
	A權重	B權重	C權重
投組A	50%	30%	20%
投組B	60%	20%	10%



$$\mathbb{E}(R_A) = (50\% \times 10\%) + (30\% \times 15\%) + (20\% \times 20\%)$$

$$\sigma_A^2 = (0.50)^2(0.05)^2 + (0.30)^2(0.10)^2 + (0.20)^2(0.20)^2$$

$$\sigma_A^2 = (0.25 \times 0.0025) + (0.09 \times 0.01) + (0.04 \times 0.04)$$

$$\sigma_A^2 = 0.000625 + 0.0009 + 0.0016 = 0.003125$$

$$\sigma_p = \sqrt{0.003125} \approx 5.59\%$$

$$\text{報酬風險比率} = \frac{\text{預期回報}}{\text{預期波動度}}$$

	預期回報	預期波動度	報酬風險比率
投組A	13.500%	5.590170%	2.41
投組B	11.000%	4.123106%	2.67

B Win!



最佳化 = 在「能量地形」中尋找最低能量的基態 (Ground State)



退火的物理直覺

源自冶金學

將金屬加熱再「緩慢冷卻」，原子得以重新排列至能量最低、最穩定的晶體結構。

類比到最佳化

投資組合配置 = 一個能量地形；最佳權重 = 能量最低的谷底。演算法要做的，就是在崎嶇地形中找到最深的那個谷。

量子絕熱定理

理論上：只要演化「夠慢」，系統會停留在瞬時基態 — 最終即為全域最佳解。

跨越山峰的兩種方式



模擬退火 SA — 靠熱能翻越

以隨機熱擾動 (Metropolis) 讓系統有機率「爬過」能量障壁，隨溫度下降逐漸凍結。傳統 CPU 即可模擬 (neal)。



量子退火 QA — 靠隧道穿牆

利用「量子隧道效應」直接穿越能量障壁，而非翻越，理論上更易逃離局部最優、找到全域基態。需真量子硬體 (如 D-Wave QPU)。



這些參數決定 QUBO 的大小與能量地形，以及退火搜尋的深度。



num_sweeps · 降溫步數

單次退火由高溫降到低溫的步數，相當於「退火時間」。本研究 P20 = 2,000 步、P100 = 8,000 步。



num_reads · 抽樣次數

重複退火的次數 — 多派幾支「探險隊」出發，最後取能量最低、且滿足預算的解。



penalty λ · 預算懲罰係數

以 $\lambda(\sum x_i - P)^2$ 把「權重和 = 100%」加入目標函數。太小會違反預算；太大會讓懲罰主導地形，退火難以在可行解之間移動。



precision · 離散精度

把資金切成 P 份：P20 每份 5%、P100 每份 1%；每檔股票分別以 5 或 7 個位元編碼。

P20 (1, 2, 4, 8, 5) P100 (1, 2, 4, 8, 16, 32, 37)



QUBO 由 *neal* (D-Wave Ocean 的古典模擬退火) 在 CPU 上求解；本研究未使用量子硬體。



precision · 權重顆粒度

將資金等分為 P 份 (每份 5% 或 1%)；50 檔股票對應 250 或 350 個二元變數。

P20
20

P100
100



penalty 係數 · λ/L

L 為每違反一個 lot 可換得的最大目標改善量； λ/L 依敏感度實驗選定。

P20
0.1

P100
0.1



num_sweeps · 降溫步數

單次退火由高溫降到低溫的總步數；地形崎嶇時需要更長的降溫過程。

P20
2,000

P100
8,000



num_reads · 取樣次數

獨立重複退火的次數；取能量最低且滿足預算的解，若全部不可行則以最大餘數法修復。

P20
100

P100
300

牽一髮而動全身

precision $\uparrow$ 20 $\rightarrow$ 100



二元變數 250 $\rightarrow$ 350



penalty $\lambda = 0.1 \cdot L$

隨問題規模自動縮放

num_sweeps $\uparrow$ 2,000 $\rightarrow$ 8,000

給予更長降溫時間

num_reads $\uparrow$ 100 $\rightarrow$ 300

提高找到可行解的機率

$\Rightarrow$ 每題 P20 約 6 秒、P100 約 155 秒




Markowitz 均值-變異數框架

預期報酬 $= w^T \mu$

投組風險 $= w^T \Sigma w$

- **效率前緣** 在給定風險下報酬最高（或給定報酬下風險最低）的投組集合——圖中紫色曲線。
- **分散投資** 利用資產間的相關結構降低整體波動，是前緣得以「彎曲」的數學根源。
- **GMVP** 前緣最左端，全域最小變異投組，只需共變異矩陣 Σ 。
- **MSRP** 資本市場線與前緣相切之點，最大化夏普比率，需同時輸入報酬與風險。





MSRP 最大夏普比率

$$\max_w w^T \mu - \lambda w^T \Sigma w$$

$$\text{s. t. } \sum_i w_i = 1, w_i \geq 0$$

同時考慮報酬與風險； λ 為風險趨避係數（後文記為 γ ）。對輸入誤差極度敏感——一點報酬預測偏差就可能觸發極端重倉。

GMVP 最小變異投組

$$\min_w w^T \Sigma w$$

$$\text{s. t. } \sum_i w_i = 1, w_i \geq 0$$

純風險問題，只需共變異矩陣 Σ 。標準二次規劃、擁有唯一全域最優解，因而對「乾淨輸入」特別穩健。



關鍵差異 金融資產的共變異矩陣天生 condition number 很大，使 MSRP 的最佳權重對輸入誤差高度放大；GMVP 不依賴報酬預測，天然較魯棒。



經典最佳化問題

$$\begin{aligned} \min \quad & (\gamma/2) \cdot w^T \Sigma w - \mu^T w \\ \text{s.t.} \quad & \Sigma w_i = 1, \quad w_i \geq 0 \end{aligned}$$



令 $w = x/P$ (資金切成 P 份) , 並把預算限制改寫成懲罰項

最終 QUBO 模型

$$\begin{aligned} \min \quad & (\gamma/2P^2) \cdot x^T \Sigma x - (1/P) \cdot \mu^T x + \lambda (\Sigma x_i - P)^2 \\ & x_i = \sum_k c_k b_{ik}, \quad b_{ik} \in \{0, 1\} \end{aligned}$$

GMVP 只保留 $(1/P^2) \cdot x^T \Sigma x$; MSRP 以 γ 掃描效率前緣 , 取事前 Sharpe 最高者

連續權重 $\rightarrow$ lot 與位元

每檔 $x_i \in \{0, \dots, P\}$ 以有界二進位編碼 : P20 用 (1,2,4,8,5) 、 P100 用 (1,2,4,8,16,32,37) 。



線性項 = 報酬

$-(1/P) \cdot \mu^T x$: 為了降低能量 , 傾向配置預期報酬高的資產。



二次項 = 風險 + 預算

$(\gamma/2P^2) \cdot x^T \Sigma x$ 懲罰共同波動 ; $\lambda (\Sigma x_i - P)^2$ 確保權重和為 100% 。

05 懲罰係數 λ 的取捨與稠密耦合



可行性 vs 搜尋品質

$\lambda > L \Rightarrow$ 最低能量解必然可行

違反 d 個 lot 的懲罰 $\lambda d^2 \geq \lambda |d| > L |d|$

但 λ 越大，懲罰越主導能量地形，退火越難在可行解之間移動。本研究依敏感度實驗取 $\lambda = 0.1 \cdot L$ ，不可行時以最大餘數法修復並記錄。

稠密耦合

$\lambda(\sum x_i - P)^2 \Rightarrow \lambda \cdot aa^T$

rank-one、沒有任何零元素 $\rightarrow$ 所有位元兩兩耦合

再加上共變異數本身幾乎沒有零元素：50 檔 $\times$ 7 位元 ≈ 350 個變數的完全圖，超過 Advantage QPU 可直接嵌入的約 177 個。



本研究定位 所有 QUBO 皆由 neal (古典模擬退火) 求解；程式保留 QPU / hybrid 介面。結論是關於 QUBO 形式與退火搜尋，而非量子效應。



每季於 0050 成分股公告日收盤決定權重，持有至下一次公告日；2025/03–2026/03 共 5 季。



輸入一 預期報酬 μ

每季以截至公告日的資料重新訓練 LSTM，預測各股未來 63 個交易日的報酬。



輸入二 共變異矩陣 Σ

公告日（含）往前 252 個交易日的日報酬，比較五種估計式（主估計式 LW-ConstCorr 事先指定）。

回測時間線

2025/03/07

每季公告日

2026/06/05



首次決策 | 公告日收盤建倉



再平衡 | 扣手續費 0.1425% 與證交稅 0.3%




回測終點 | 第 5 季結束

季內買進持有、不再平衡；基準為等權重（每季再平衡、計成本）與 0050 ETF 買進持有。




以 2025/03 為例；每季依公告的成分股名單調整投資範圍 (49-51 檔)。

產業投資比重




個股投資比重





Forward 1-Quarter Return



標籤的統計特性


- **右偏分布**
報酬集中於 0 附近並向右拖出長尾——少數飆股貢獻多數數超額報酬。
- **每季以決策日為基準**
只使用標籤在決策日前已實現的樣本，避免資料窺探。
- **預測難度高**
季報酬絕對數值雜訊大，這也是後續模型 R^2 偏低的根本原因。



每季以決策日為基準往前推算，在訓練與驗證之間設置隔離區 (purge)，阻斷季報酬標籤的時間洩漏。

每檔股票的資料切分 (每季重做)

← 上市日 (最早 1994 年)



訓練 / 驗證：只用標籤在決策日前已實現的樣本，依時間先後切分。

樣本外預測：決策日前最後 63 個交易日的標籤要到決策日後才實現，只做預測、不參與訓練。

決策日當天的預測即為該季的 μ 。

防洩漏的四個規則

1 標籤截止

訓練樣本 t 必須滿足 $t + 63 \leq \text{決策日}$ ，確保標籤在決策當下已知。

2 Purge 隔離區

訓練與驗證之間空出 63 個交易日，避免重疊的季報酬標籤互相洩漏。

3 標準化只看訓練段

每檔股票的 StandardScaler 只在訓練段 fit，再套用到驗證與預測。

4 每季重新訓練

5 個決策日各自重新訓練、固定亂數種子 (TensorFlow deterministic ops)。




模型結構 (7,201 參數)

Layer	Output	Params
Input (63 日 × 19 特徵)	(63, 19)	0
LSTM(32, tanh)	(32)	6,656
Dropout(0.35)	(32)	0
Dense(16)	(16)	528
LeakyReLU(0.1)	(16)	0
Dense(1)	(1)	17
Total		7,201

跨 50 檔股票合併訓練；Adam、MSE loss、batch 512。刻意壓縮容量，降低在高雜訊季報酬上的過擬合。

訓練損失收斂趨勢 · 5 季各自訓練



驗證損失多在前幾個 epoch 就觸底，之後回升 — 季報酬的可預測訊號有限。Early Stopping (patience = 10) 保留驗證損失最低的權重。

06 ER 預測：模型表現（5 季平均）



0.09

Rank IC

決策日前 63 日樣本外，各季 0.01–0.17

61%

方向準確率

5 季平均（多頭期間偏多預測占優）

0.02

決策日 Rank IC


決策日 μ vs 實際持有期報酬

−0.25

R^2

預測水準普遍偏高

實際 vs 預測（未來一季報酬）



這組 μ 能用嗎？

排序有訊號，但不穩定。

決策日前 63 日的平均 Rank IC 為 0.09，但各季從 0.01 到 0.17；真正用來建倉的決策日預測，與持有期報酬的排序相關平均只有 0.02。

對最佳化的意涵：


MSRP 高度依賴 μ ，預測雜訊會被最佳化器放大 — 這是後續樣本外結果的重要背景。

06 共變異矩陣估計：五種數值方法



決策日 (含) 往前 252 個交易日的日報酬，換算為季化單位；收縮估計式把條件數降低約 2-4 倍。

共變異矩陣的條件數 (越大越接近奇異、對估計誤差越敏感)



Sample

傳統樣本共變異；條件數中位數約 720

EWMA

指數加權 (span 180) ；條件數約 760

LW-Identity

收縮至單位矩陣；條件數最低，約 170

LW-ConstCorr

收縮至固定相關係數；主估計式

LW-Factor

收縮至單因子 (市場) 模型



同一組 μ 、 Σ 下比較；QUBO 以 *neal* (CPU 上的古典模擬退火) 求解。時間為每個最佳化問題的中位數。

方法	解空間	求解器	每題時間
MVO	連續	PyPortfolioOpt (cvxpy)	0.01 秒
MVO + 10% 上限	連續	同上，單一權重 $\leq 10\%$	0.01 秒
MVO 四捨五入	1/P 格點	凸最佳解 + 最大餘數法	≈ 0
連續 SA	連續	scipy dual_annealing	2.5 秒
QUBO-P20	250 個二元變數	neal · 100 reads × 2,000 sweeps	6 秒
QUBO-P100	350 個二元變數	neal · 300 reads × 8,000 sweeps	155 秒

時間級距解讀

MVO 不到 0.1 秒

凸最佳化求得全域最佳解

連續 SA 約 2.5 秒

直接在連續權重上搜尋，結果與 MVO 幾乎相同

QUBO-P20 約 6 秒


250 個二元變數、全連接

QUBO-P100 約 155 秒

350 個二元變數、8,000 sweeps；比 MVO 慢上千倍



2025/03 · LW-ConstCorr：所有解皆以相同的事前 μ 、 Σ 評估




觀察重點

- 連續 SA $\approx$ MVO**
 連續空間的退火找得到凸最佳解，兩者權重幾乎相同。
- QUBO 解在前緣內側**
 同樣風險下預期報酬較低 — 退火沒有收斂到最佳解。
- QUBO 解更分散**
 GMVP 的有效持股數 7–14 檔，MVO 約 3 檔。



QUBO + 模擬退火 vs 連續最佳解 vs 「把凸最佳解四捨五入到同一格點」(5季 × 5估計式的平均)。

均值—變異數問題：與連續最佳解的確定等值損失



	MV 損失 (每季)	GMVP 波動倍數
QUBO-P20	103 bp	1.21×
QUBO-P100	397 bp	1.31×
四捨五入 P20	4 bp	1.01×
四捨五入 P100	< 0.1 bp	1.00×



離散化不是瓶頸

把凸最佳解四捨五入到同樣的 $1/P$ 格點，損失只有 $< 0.1-4$ bp；問題出在退火的搜尋，而非格點本身。



精度越高越差

P100 每季損失約 397 bp，是 P20 (103 bp) 的 4 倍：位元更多、最高位係數 37，能量地形更崎嶇。




可行率與修復

預算可行率：GMVP 90–97%，均值—變異數約 50–57% (γ 小時偏低)；被選為 MSRP 的解中，P100 有 12% 經過修復。



只使用 2025/03 決策日的事前輸入，以目標函數評估 — 不涉及任何未來報酬資料。

$\lambda / L \times \text{sweeps}$ 對解品質的影響 (虛線為選定的 0.1)



λ 越小，解越好

λ 從 $2L$ 降到 $0.1L$ ，GMVP 的超額波動由 55–70% 降到 20–41%。
 $\lambda > L$ 雖保證可行，卻讓懲罰主導地形。



sweeps 幾乎無效

2,000 $\rightarrow$ 32,000 sweeps (16 倍) 幾乎沒有改善：瓶頸在能量地形，而非退火時間。



選定 $\lambda = 0.1 \cdot L$


規則：預設 sweeps 下，所有設定可行率皆 $\geq 50\%$ 的最小係數。 λ 太小 (0.05) 時可行率趨近 0。



主估計式 $LW-ConstCorr$ ；虛線為基準。所有方法皆每季於公告日再平衡。

累積報酬：GMVP（左）與 MSRP（右）

Walk-forward out-of-sample performance



多頭行情下的結果 所有最佳化組合都遠落後 0050（+128%）與等權重（+81%）；QUBO 組合領先 MVO，但領先幅度與其較高的 beta 一致。



年化報酬 · 波動 · Sharpe · 最大回撤 · 對 0050 的 beta

組合	方法	報酬	波動	Sharpe	MDD	Beta
GMVP	MVO	7.0%	11.7%	0.64	-7.5%	0.18
GMVP	連續 SA	7.0%	11.7%	0.64	-7.5%	0.18
GMVP	QUBO-P20	14.9%	13.3%	1.11	-9.3%	0.28
GMVP	QUBO-P100	18.3%	14.6%	1.26	-12.0%	0.37
GMVP	MVO + 10% 上限	2.9%	13.2%	0.28	-9.7%	0.28
MSRP	MVO	19.6%	24.7%	0.85	-17.8%	0.49
MSRP	連續 SA	19.6%	24.7%	0.85	-17.8%	0.49
MSRP	QUBO-P20	26.9%	30.2%	0.90	-21.8%	0.63
MSRP	QUBO-P100	30.9%	29.6%	1.06	-21.3%	0.69
MSRP	MVO + 10% 上限	21.3%	20.8%	1.02	-16.9%	0.52
基準	等權重	63.6%	23.1%	2.25	-20.5%	0.75
基準	0050 ETF	98.2%	27.1%	2.67	-21.1%	1.00

研究期間的市場


+128%

0050 ETF 五季累積報酬（含權息）

+81%


等權重五季累積報酬（扣成本）

Sharpe：基準 vs GMVP 組合





每季持有期報酬 (LW-ConstCorr)



平均名次 (7 種方法)

MSRP

QUBO-P100 2.6 · QUBO-P20 3.2 · MVO+10% 3.6 · 四捨五入 4.5–4.6 · 連續 SA 4.7 · MVO 4.9

GMVP


QUBO-P20 2.6 · QUBO-P100 2.7 · 四捨五入 P100 3.6 · MVO 4.1 · 連續 SA 4.1 · 四捨五入 P20 5.0 · MVO+10% 5.9

同一估計式、同組合類型下比較季報酬 (1 = 最好) · 25 組的平均。5 季皆為多頭，名次差異不具統計顯著性。



以 β 與分散度解釋，並以「MVO + 10% 權重上限」作為顯式正則化的對照組。

對 0050 的 β (中位數)



①

QUBO 較分散、 β 較高

QUBO-GMVP 的有效持股數 7-14 檔 (MVO 約 3 檔)， β 0.37 vs 0.18；在 0050 上漲 128% 的期間，較高的市場曝險直接轉為較高報酬。以 GMVP 的本意 (低波動) 衡量，MVO 的實現波動 11.7%、回撤 -7.5% 仍較佳。

②

10% 權重上限可複製 MSRP 的效果

MVO 加上單一權重 $\leq 10\%$ ：MSRP Sharpe 1.02 (QUBO-P100 為 1.06)，且波動 20.8% vs 29.6%、回撤 -16.9% vs -21.3% 都更低。GMVP 加上限則沒有改善 (0.28)，顯示 QUBO-GMVP 的優勢來自保留的市場曝險。



量子絕熱定理：理想與現實的斷層

絕熱定理保證「只要時間夠長，必收斂到最佳解」——但實際求解時為何仍與最佳解有差距？



本研究使用古典退火

neal 的 SimulatedAnnealingSampler 是 CPU 上的模擬退火，靠熱擾動翻越障壁，不受絕熱定理保證。



真量子也受物理限制

絕熱時間 $\tau \propto 1/\Delta_{\min}^2$ 。精度變細 $\rightarrow$ 能隙 $\Delta_{\min}$ 可能趨近 0 $\rightarrow$ 所需時間急遽增加。



sweeps 不是萬靈丹

敏感度實驗中，sweeps 增加 16 倍幾乎沒有改善；瓶頸在懲罰項主導的能量地形，而非退火時間。

$$\tau \propto \frac{1}{\Delta_{\min}^2}$$

能隙坍塌 當 precision 從 20 $\rightarrow$ 100，大量次優解的能量與最優解極接近，最小能隙趨近 0。真實 QPU 能否改善，需要在可嵌入的規模上實測——這是本研究的未來方向。

研究總結與核心洞察

Research Summary & Core Insights



01

解品質的瓶頸在懲罰地形

同一目標函數下，QUBO + 模擬退火每季損失 1.0–4.0 個百分點的確定等值報酬；把凸最佳解四捨五入到同一格點幾乎無損失。 λ 越小解越好、sweeps 幾乎無助，P100 比 P20 更差。



02

解得較差 $\neq$ 投資較差，但那是 beta

QUBO 組合較分散、beta 較高 (GMVP 0.37 vs 0.18)，在 0050 上漲 128% 的期間樣本外 Sharpe 較高；以 GMVP 的低波動目標衡量 MVO 仍較佳，MSRP 的效果可被 10% 權重上限複製。



03

被動基準與量子的位置

等權重 Sharpe 2.25、0050 2.67，皆遠勝最佳化組合；LSTM 決策日 IC 僅 0.02。50 檔 long-only 是凸問題，量子方法若有價值，應在基數限制、整張交易與階梯成本等古典困難的設定中檢驗。

核心洞察 「解得好」不等於「投資好」，但「解得差」也不是 alpha — 先拆解 beta 與分散度，再談求解器的價值。



研究限制

沒有量子硬體

所有 QUBO 結果來自 neal 古典模擬退火，不能推論真實 QPU 的表現。

樣本小、行情單一

只有 5 季、全部落在強勁多頭，無法以統計檢定區分 beta 與 alpha。

預期報酬近乎雜訊

MSRP 的結論高度依賴 μ 的品質；QUBO 版 MSRP 以 γ 網格近似。



未來方向

顯式 vs 隱式正則化

以權重上限、L2、收縮與重抽樣前緣，系統性檢驗離散化的效果能否被複製。

走向古典困難的問題

基數限制、整張交易單位、階梯手續費與多期動態 — 先確認 Gurobi 真的變慢。

真實 QPU 與 hybrid 實測

在可嵌入的規模上比較 QPU、neal、tabu 與 Leap hybrid (BQM / CQM)。



附 錄 · Appendix

業界實務的投資組合最佳化方法

為何「Softmax 排名 + GMVP 線性組合」優於直接組 MSRP



實務最佳化流程：排名 $\rightarrow$ Softmax $\rightarrow$ 線性組合

不直接輸出權重，而是讓模型預測「季報酬率排名」，再經多步轉換建構穩健投組。



為何要線性組合？ Softmax(模型 alpha) 提供進攻性、GMVP 提供風險分散；兩者融合兼顧 alpha 與穩健，避免單一來源的極端配置。



MSRP 的脆弱性

極度依賴輸入準確度

MSRP 同時吃「預期報酬」與「共變異」，權重好壞高度受輸入準確度左右。

病態的共變異矩陣

金融資產的 Σ 天生 condition number 很大；矩陣求逆時，輸入的微小誤差會被劇烈放大。

權重劇烈跳動

一點點報酬預測偏差，就足以讓 MSRP 算出的最佳權重大幅變動，甚至 All-in 單一資產。



線性組合的優勢

GMVP 不吃報酬預測

GMVP 只需共變異矩陣，避開最不可靠的「未來報酬預測」這一環。

Softmax 提供溫和 alpha

以排名（而非絕對數值）驅動權重，天然抑制極端值，比 MSRP 的硬最佳化更平滑。

兩者互補、抗雜訊

50% 模型 + 50% GMVP，在追逐 alpha 的同時保有分散防禦，降低對報酬預測精度的依賴。