




量子 × 投資組合最佳化研究

Application of Quantum & Simulated Annealing on Portfolio Optimization



以模擬退火與量子退火求解 MSRP / GMVP — QUBO 形式下的投資組合最佳化，並於 0050 成分股進行樣本外回測比較

較
金融四雙應數-溫亮達



簡報大綱

Agenda

本簡報依研究筆記脈絡，從量子退火原理出發，建立 MSRP / GMVP 的 QUBO 模型，並以實證結果比較古典解與退火解的優劣。



01

量子退火演算法

退火、能量基態與量子隧道



02

量子退火的超參數

sweeps · reads · 懲罰 · 精度



03

現代投資組合理論與效率前緣

Markowitz 均值-變異數框架



04

MSRP 與 GMVP

最大夏普 vs 最小變異投組



05

MSRP / GMVP → QUBO

二元化、預算限制與懲罰函數



06

策略與資料：0050 與 LSTM

權重、標籤分布、ER 預測、共變異



07

四演算法實證比較

時間 · 權重 · 精確度陷阱 · 樣本外



	買他以後未來一季預期賺n% (預期報酬)	未來一季報酬率的波動度(標準差)	
股票A	10%	5%	
股票B	15%	10%	
股票C	20%	20%	
	A權重	B權重	C權重
投組A	50%	30%	20%
投組B	60%	20%	10%



$$\mathbb{E}(R_A) = (50\% \times 10\%) + (30\% \times 15\%) + (20\% \times 20\%)$$

$$\sigma_A^2 = (0.50)^2(0.05)^2 + (0.30)^2(0.10)^2 + (0.20)^2(0.20)^2$$

$$\sigma_A^2 = (0.25 \times 0.0025) + (0.09 \times 0.01) + (0.04 \times 0.04)$$

$$\sigma_A^2 = 0.000625 + 0.0009 + 0.0016 = 0.003125$$

$$\sigma_p = \sqrt{0.003125} \approx 5.59\%$$

$$\text{報酬風險比率} = \frac{\text{預期回報}}{\text{預期波動度}}$$

	預期回報	預期波動度	報酬風險比率
投組A	13.500%	5.590170%	2.41
投組B	11.000%	4.123106%	2.67

B Win!



最佳化 = 在「能量地形」中尋找最低能量的基態 (Ground State)



退火的物理直覺

源自治金學

將金屬加熱再「緩慢冷卻」，原子得以重新排列至能量最低、最穩定的晶體結構。

類比到最佳化

投資組合配置 = 一個能量地形；最佳權重 = 能量最低的谷底。演算法要做的，就是在崎嶇地形中找到最深的那個谷。

量子絕熱定理

理論保證：只要演化「夠慢」，系統必以 100% 機率停留在基態 — 即找到全域最佳解。

跨越山峰的兩種方式



模擬退火 SA — 靠熱能翻越

以隨機熱擾動 (Metropolis) 讓系統有機率「爬過」能量障壁，隨溫度下降逐漸凍結。傳統 CPU 即可模擬 (neal)。



量子退火 QA — 靠隧道穿牆

利用「量子隧道效應」直接穿越能量障壁，而非翻越，理論上更易逃離局部最優、找到全域基態。需真量子硬體 (如 D-Wave QPU)。



這些超參數，本質上是我們在傳統電腦上「用人工算力去逼近絕熱定理那段無限久時間」的控制閥。



num_sweeps · 降溫步數

模擬退火中等同於「時間」。步數越多越接近絕熱演化；本研究 QA20 = 2,000 步、QA100 提高到 8,000 步。



num_reads · 抽樣次數

重複退火的次數 — 多派幾支「探險隊」出發，最後取能量最低的生還者，以統計抽樣彌補單次時間不足。



lagrange_multiplier · 拉格朗日乘子

將約束（如總份數 = 100）以懲罰函數打包進目標函數。過高會把限制邊界拉得像長城，反而綁死尋優。



precision · 離散精度

把連續權重切成 N 份。QA20 = 21 級（5%）、QA100 = 101 級（1%）；越細，解空間呈幾何級數暴增。

0 / 20 / 40 / 60 / 80 / 100 vs 0 / 1 / 2 / ... / 100



本研究的量子退火模擬器的超參數設定

這四個閥門控制著從數學公式 (CQM) → 物理模型 (BQM/QUBO) 的轉譯，以及模擬計算的深度；彼此「牽一髮而動全身」。



precision · 權重顆粒度

將 100% 資金等分為 N 份 (20→每份 5%、100→每份 1%)；越細，二元組合數呈幾何級數暴增。

QA20
20

QA100
100



lagrange_multiplier · 懲罰權重

強迫總權重 = 100% 的「法律警棍」。precision↑ 使風險能量約暴增 25 倍，懲罰須同步拉高否則模型作弊。

QA20
5.0

QA100
15.0



num_sweeps · 降溫步數

單次退火由高溫降到凍結的總步數。針狀地形須緩慢降溫，否則 Quenching 會卡在局部次優解。

QA20
2,000

QA100
8,000



num_reads · 取樣次數

獨立重複退火的次數 (派幾支探險隊)。過濾無效解後只取能量最低者；精度越高越易迷路，須提高勝率。

QA20
100

QA100
300

牽一髮而動全身

precision ↑ 20 → 100



解空間複雜度爆炸



lagrange ↑ 5.0 → 15.0

防止模型不守法

num_sweeps ↑ 2000 → 8000

給予更長降溫時間

num_reads ↑ 100 → 300

提高多樣本抽樣勝率

⇒ Precision_100 耗時跨越式暴增




Markowitz 均值-變異數框架

預期報酬 = $w^T \mu$

投組風險 = $w^T \Sigma w$

- **效率前緣** 在給定風險下報酬最高（或給定報酬下風險最低）的投組集合——圖中紫色曲線。
- **分散投資** 利用資產間的相關結構降低整體波動，是前緣得以「彎曲」的數學根源。
- **GMVP** 前緣最左端，全域最小變異投組，只需共變異矩陣 Σ 。
- **MSRP** 資本市場線與前緣相切之點，最大化夏普比率，需同時輸入報酬與風險。





MSRP 最大夏普比率

$$\max_w w^T \mu - \lambda w^T \Sigma w$$

$$\text{s. t. } \sum_i w_i = 1, w_i \geq 0$$

同時考慮報酬與風險； λ 為風險趨避係數。對輸入誤差極度敏感 — 一點報酬預測偏差就可能觸發極端重倉。

GMVP 最小變異投組

$$\min_w w^T \Sigma w$$

$$\text{s. t. } \sum_i w_i = 1, w_i \geq 0$$

純風險問題，只需共變異矩陣 Σ 。標準二次規劃、擁有唯一全域最優解，因而對「乾淨輸入」特別穩健。



關鍵差異 金融資產的共變異矩陣天生 condition number 很大，使 MSRP 的最佳權重對輸入誤差高度放大；GMVP 不依賴報酬預測，天然較魯棒。



經典最佳化問題

$$\begin{aligned} \max \quad & \sum_{i=1}^n x_i e_i - \theta \sum_{i,j=1}^n x_i x_j c_{ij} \\ \text{s. t.} \quad & \sum_{i=1}^n x_i b_i \leq B \end{aligned}$$



乘上負號 → 最小化 (契合尋找最低能量基態)

最終 QUBO 模型

$$\begin{aligned} \min \quad & - \sum_{i=1}^n x_i e_i + \theta \sum_{i,j=1}^n x_i x_j c_{ij} \\ & x_i \in \{0, 1\} \end{aligned}$$

預算限制 → 懲罰函數 / 鬆弛變數 → 完全無約束二次模型



連續權重 → 二元選擇

w_i 從「分配多少%」變成 $x_i \in \{0, 1\}$ 「要不要買」，形同背包問題。
多 bit 可表示 0/25/50/75/100%。



線性項 = 報酬

$-\sum x_i e_i$ ：演算法為降低能量，傾向選入預期報酬高的資產。



二次項 = 風險 / 分散

$+\theta \sum x_i x_j c_{ij}$ ：同時選入高度正相關資產會推高能量，演算法自動避開 → 體現分散投資。



假設在 2025/03/07 公布名單後，決定下一季（至下個換股日 2025/06/06）的最佳投資組合。



輸入一 每支股票預期報酬率

以 LSTM 預測 2025/03/07 當下、對未來一季的每日報酬率，作為 e_i 輸入。



輸入二 共變異矩陣 Σ

以 2025/03/07 回推一年的每日報酬率計算，並測試多種數值估計方法。

回測時間線

2025/03/07

2025/03/24

2025/06/06



公布名單日 | 權重計算與鎖定



實際換股日




回測終點 | 下個換股日

在 3/7 算出最佳化權重後即「凍結」（期間內不再平衡），直接帶入未來真實資料做樣本外回測。




名單公布當月 (2025_03) 成分股的產業與個股投資比重分布。

產業投資比重




個股投資比重





Forward 1-Quarter Return



標籤的統計特性


- **右偏分布**
報酬集中於 0 附近並向右拖出長尾 — 少數飆股貢獻多數數超額報酬。
- **以名單公布日為基準**
僅取 2025/03/07 之前的真實歷史，避免資料窺探。
- **預測難度高**
季報酬絕對數值雜訊大，這也是後續模型 R^2 偏低的根本原因。



以名單公布日為基準，由後往前推算，並設置雙重「隔離緩衝區 (Gap)」阻斷季報酬標籤的時間洩漏。

各股完整量化流水線時間軸

每支股票完整量化流水線時間軸分佈圖 (含雙重防走光隔離帶與時間佔比)




全市場 50 檔 · 各階段資料量佔比

● 全市場 50 支股票總累積資料天數: 433,075 天

Phase	Total_Days	Percentage (%)
1. Training Set (訓練集)	354554	81.87
2. Purge Buffer 1 (隔離區一)	4719	1.09
3. Validation Set (驗證集)	59502	13.74
4. Purge Buffer 2 (隔離區二)	4800	1.11
5. Testing Set (測試集)	9500	2.19

綜合全市場股票各階段資料量總體佔比 (總計: 433,075 天)





模型結構 (21,989 參數)

Model: "sequential_3"

Layer (type)	Output Shape	Param #
lstm_5 (LSTM)	(None, 32)	6,784
dropout_5 (Dropout)	(None, 32)	0
dense_6 (Dense)	(None, 16)	528
leaky_re_lu (LeakyReLU)	(None, 16)	0
dense_7 (Dense)	(None, 1)	17

Total params: 21,989 (85.90 KB)


Trainable params: 7,329 (28.63 KB)

Non-trainable params: 0 (0.00 B)

Optimizer params: 14,660 (57.27 KB)

LSTM(32) → Dropout(35%) → Dense(16)+LeakyReLU → Dense(1)。刻意壓縮容量，強迫模型萃取跨越 20 年最具泛化力的時序精華。

訓練損失收斂趨勢 · Early Stopping



資料量少 → 簡單架構仍易過擬合。驗證損失於早期觸底後回升，故以 Early Stopping (patience = 10) 提早煞車，保留最佳泛化權重。



0.1497

IC

Rank IC · 量化多因子 > 0.05 即優秀

55.56%

方向準確率

顯著超越 50% 擲硬幣門檻

0.1197

MAE


平均絕對誤差

0.0464

 R^2

季報酬絕對值極難預測，屬正常

實際 vs 預測（未來一季報酬）



為何是「極度成功」的因子？

 R^2 雖低，但 IC 才是關鍵。


Rank IC = 0.1497 代表模型算出的「報酬排名」與未來真實強弱排名高度契合 — 在全市場單一模型中屬鳳毛麟角。

實務用法：

預測排名 → Softmax 權重 → 挑前 n% → 與 GMVP 線性組合，比直接組 MSRP 更穩健（詳見附錄）。



以 2025/03/07 回推一年每日報酬計算 Σ ，並比較歷史估計量與「未來真實」共變異結構。



Sample

傳統樣本共變異，雜訊大

EWMA

指數加權，重視近期

LW-Identity

Ledoit-Wolf 線性收縮

LW-ConstCorr


固定相關係數收縮

LW-Factor

單因子（市場）收縮



比較 MVO (解析)、SA、QA20 (找解細度設為 0/20/40/60/80/100)、QA100 (將找解細度設為 0/1/2/3/.../99/100) 的耗時。



	MVO	SA	QA20	QA100
Model_Name				
01_Answer_Actual	0.0268秒	2.6851秒	5.6220秒	147.3215秒
02_Sample	0.0109秒	2.6470秒	5.7068秒	150.7721秒
03_EWMA	0.0115秒	2.6686秒	5.6675秒	149.4303秒
04_LedoitWolf_Identity	0.0125秒	2.6271秒	5.6271秒	150.7083秒
05_LedoitWolf_ConstCorr	0.0116秒	2.6197秒	5.6918秒	150.0717秒
06_LedoitWolf_Factor	0.0111秒	2.6089秒	5.6802秒	152.0794秒

時間級距解讀

MVO 微秒級

凸優化解析解，幾乎瞬殺

SA 秒級

連續空間梯度尋優，無需二元拆解

QA20 數秒

變數切 20 份


QA100 秒至分鐘

解空間幾何暴增 + sweeps 8000，耗時數倍



Algorithm Weight Allocation : GMVP vs MSRP

Algorithm Weight Allocation Comparison:
01_Answer_Actual (MVO vs SA vs QA20 vs QA100)



模型誤差統計表 (衡量 SA / QA20 / QA100 與 MVO 的整體差距)

	SA 平均絕對 誤差 (MAD)	SA 最大絕對 誤差 (Max Diff)	QA20 平均絕對 誤差 (MAD)	QA20 最大絕對 誤差 (Max Diff)	QA100 平均絕對 誤差 (MAD)	QA100 最大絕對 誤差 (Max Diff)
01_Answer_Actual_GMVP	0.00%	0.03%	3.00%	37.30%	3.18%	44.30%
01_Answer_Actual_MSRP	0.00%	0.00%	3.80%	57.96%	3.96%	57.96%
02_Sample_GMVP	0.00%	0.01%	2.85%	38.77%	2.45%	40.77%
02_Sample_MSRP	0.00%	0.00%	3.09%	62.80%	3.59%	82.80%
03_EWMA_GMVP	0.00%	0.02%	3.06%	54.03%	3.45%	58.03%
03_EWMA_MSRP	0.00%	0.00%	2.76%	52.14%	3.32%	62.14%
04_LedoitWolf_Identity_GMVP	0.01%	0.08%	2.54%	15.26%	2.33%	18.26%
04_LedoitWolf_Identity_MSRP	0.00%	0.00%	3.30%	75.42%	3.75%	80.42%
05_LedoitWolf_ConstCorr_GMVP	0.00%	0.04%	2.48%	33.42%	2.71%	38.42%
05_LedoitWolf_ConstCorr_MSRP	0.00%	0.00%	3.43%	72.86%	3.64%	76.86%
06_LedoitWolf_Factor_GMVP	0.00%	0.02%	3.10%	45.15%	2.72%	46.15%
06_LedoitWolf_Factor_MSRP	0.00%	0.00%	3.00%	58.50%	3.76%	78.50%



觀察重點

- **SA ≈ MVO**
兩者權重幾乎無差異 — SA 在連續空間逼近解析解。
- **QA 趨向分散**
離散編碼讓 QA 無法極端重倉，被迫分散持有。
- **QA20 比 QA100 更接近解析解**
粗顆粒地形簡單，反而更易踩到全域最佳。



反直覺結果：格子更細的QA100，誤差在多數模型中反而比QA20 還大 → 在傳統電腦上使用模擬器對我的超參數選擇造成限制

QA20 vs QA100 權重的不同程度 (MAD / Max Diff)

	QA20 vs QA100 平均絕對差異 (MAD)	QA20 vs QA100 最大絕對差異 (Max Diff)
01_Answer_Actual_GMVP	2.36%	9.00%
01_Answer_Actual_MSRR	2.60%	28.00%
02_Sample_GMVP	2.24%	11.00%
02_Sample_MSRR	3.04%	20.00%
03_EWMA_GMVP	3.24%	20.00%
03_EWMA_MSRR	2.76%	19.00%
04_LedoitWolf_Identity_GMVP	2.48%	10.00%
04_LedoitWolf_Identity_MSRR	2.60%	14.00%
05_LedoitWolf_ConstCorr_GMVP	2.68%	19.00%
05_LedoitWolf_ConstCorr_MSRR	3.00%	19.00%
06_LedoitWolf_Factor_GMVP	2.44%	13.00%
06_LedoitWolf_Factor_MSRR	3.12%	20.00%

模型誤差統計表 (衡量 SA / QA20 / QA100 與 MVO 的整體差距)

	SA 平均絕對 誤差 (MAD)	SA 最大絕對 誤差 (Max Diff)	QA20 平均絕 對誤差 (MAD)	QA20 最大絕對 誤差 (Max Diff)	QA100 平均絕 對誤差 (MAD)	QA100 最大絕對 誤差 (Max Diff)
01_Answer_Actual_GMVP	0.00%	0.03%	3.00%	37.30%	3.18%	44.30%
01_Answer_Actual_MSRR	0.00%	0.00%	3.80%	57.96%	3.96%	57.96%
02_Sample_GMVP	0.00%	0.01%	2.85%	38.77%	2.45%	40.77%
02_Sample_MSRR	0.00%	0.00%	3.09%	62.80%	3.59%	82.80%
03_EWMA_GMVP	0.00%	0.02%	3.06%	54.03%	3.45%	58.03%
03_EWMA_MSRR	0.00%	0.00%	2.76%	52.14%	3.32%	62.14%
04_LedoitWolf_Identity_GMVP	0.01%	0.08%	2.54%	15.26%	2.33%	18.26%
04_LedoitWolf_Identity_MSRR	0.00%	0.00%	3.30%	75.42%	3.75%	80.42%
05_LedoitWolf_ConstCorr_GMVP	0.00%	0.04%	2.48%	33.42%	2.71%	38.42%
05_LedoitWolf_ConstCorr_MSRR	0.00%	0.00%	3.43%	72.86%	3.64%	76.86%
06_LedoitWolf_Factor_GMVP	0.00%	0.02%	3.10%	45.15%	2.72%	46.15%
06_LedoitWolf_Factor_MSRR	0.00%	0.00%	3.00%	58.50%	3.76%	78.50%



解空間幾何級數暴增

精度 20→100，每檔選擇 21→101 種，能量地形從平緩丘陵變成佈滿局部極小的「針狀地形」。



降溫步數跟不上

sweeps 僅 4 倍，解空間複雜度卻暴增數十倍 → 半路就凍結在次優解。



懲罰項副作用

lagrange 5→15 把限制邊界拉得過高，退火器不敢偏離，限縮了尋優能力。



以測試集真實的季報酬與 Σ 組出的MSRP / GMVP為基準，比較各演算法權重誤差。

🏆 [GMVP Overall Winner]: 03_EWMA (MVO_Error)
-> Average Weight Deviation: 1.6556%

	MVO_Error	SA_Error	QA20_Error	QA100_Error
Model				
02_Sample	1.7958%	1.7966%	3.4000%	3.3388%
03_EWMA	1.6556%	1.6558%	3.6000%	3.3989%
04_LedoitWolf_Identity	2.5113%	2.5083%	3.0000%	3.5200%
05_LedoitWolf_ConstCorr	1.8423%	1.8429%	3.1801%	3.2389%
06_LedoitWolf_Factor	1.8642%	1.8651%	3.2000%	3.5166%

🏆 [MSRP Overall Winner]: 02_Sample (QA100_Error)
-> Average Weight Deviation: 3.5200%

	MVO_Error	SA_Error	QA20_Error	QA100_Error
Model				
02_Sample	3.9879%	3.9879%	4.0000%	3.5200%
03_EWMA	4.0000%	4.0000%	4.0000%	3.6800%
04_LedoitWolf_Identity	3.9843%	3.9843%	3.8000%	3.6000%
05_LedoitWolf_ConstCorr	4.0000%	4.0000%	4.0000%	3.7600%
06_LedoitWolf_Factor	4.0000%	4.0000%	4.0000%	3.8800%

①

GMVP：MVO 完勝

純風險、輸入乾淨的問題擁有唯一全域最優解。MVO 的連續精確度像手術刀，能算出最完美配比；QA 受離散與收斂瓶頸所限，誤差卡在 3% 以上。冠軍為 03_EWMA (1.66%)。

②


MSRP：QA100 橫掃全場錯誤的解反而帶來Robustness與更好的實盤表現

含雜訊報酬預測時，精確的 MVO 變成「雜訊放大器」— 全力 All-in 被高估的股票而全面翻車（誤差卡死 4%）。QA 解風險趨避替代模型 + 離散強迫分散 = 雙重防禦禦傘，意外修正錯誤，冠軍 02_Sample (3.52%)。




2025/03 - 06 樣本外回測：使用真實正解 vs 使用 EWMA 估計，GMVP 與 MSRP 走勢對照。

01 · 真實正解 (Answer Actual)



03 · EWMA 估計



荒謬而美麗的現象 用真實高品質輸入時，確定性解析解確實找到最佳解；但預測未來時（金融數據天生帶雜訊），QA 的「不準」反而為最佳權重增添了 robustness，表現更佳。



四演算法績效橫向對比 (Calmar · 累積報酬 · 最大回撤)

🏆 四大演算法績效橫向對比總表 (MVO vs SA vs QA20 vs QA100)

💡 閱讀指南：

- 累積報酬率 (獲利) 最佳者標示為 金黃色
- 最大回撤 (防禦) 最佳者標示為 亮綠色
- 卡瑪比率 (綜合) 最佳者標示為 亮藍色

	Metric	Calmar Ratio				Cumulative Return				Max Drawdown			
	Algo	MVO	SA	QA20	QA100	MVO	SA	QA20	QA100	MVO	SA	QA20	QA100
	01_Answer_Actual_GMVP	0.03	0.03	-0.03	-0.17	0.14%	0.14%	-0.32%	-2.21%	-4.87%	-4.87%	-11.81%	-12.92%
	01_Answer_Actual_MSRR	0.77	0.77	-0.16	-0.22	11.07%	11.07%	-2.05%	-3.15%	-14.44%	-14.44%	-12.50%	-14.37%
	02_Sample_GMVP	-0.30	-0.30	-0.10	-0.24	-2.09%	-2.09%	-1.45%	-3.82%	-7.06%	-7.07%	-14.95%	-16.21%
	02_Sample_MSRR	-0.27	-0.27	-0.04	-0.16	-6.47%	-6.47%	-0.93%	-2.46%	-23.80%	-23.80%	-20.86%	-15.59%
	03_EWMA_GMVP	-0.19	-0.19	0.01	-0.11	-1.30%	-1.30%	0.11%	-1.74%	-6.79%	-6.79%	-15.32%	-16.38%
	03_EWMA_MSRR	-0.25	-0.25	-0.29	-0.06	-5.22%	-5.22%	-4.34%	-0.97%	-21.19%	-21.19%	-15.04%	-15.74%
	04_LedoitWolf_Identity_GMVP	-0.38	-0.38	-0.28	-0.19	-3.21%	-3.20%	-4.14%	-2.79%	-8.52%	-8.51%	-14.62%	-14.72%
	04_LedoitWolf_Identity_MSRR	-0.27	-0.27	-0.17	-0.11	-6.49%	-6.49%	-3.52%	-1.65%	-23.76%	-23.76%	-20.93%	-15.07%
	05_LedoitWolf_ConstCorr_GMVP	-0.27	-0.27	-0.26	-0.04	-1.86%	-1.87%	-3.82%	-0.72%	-6.96%	-6.97%	-14.64%	-16.10%
	05_LedoitWolf_ConstCorr_MSRR	-0.32	-0.32	-0.26	-0.21	-7.53%	-7.53%	-5.15%	-3.69%	-23.33%	-23.33%	-19.82%	-17.54%
	06_LedoitWolf_Factor_GMVP	-0.32	-0.32	-0.25	-0.11	-2.29%	-2.29%	-3.59%	-1.88%	-7.08%	-7.08%	-14.26%	-16.60%
	06_LedoitWolf_Factor_MSRR	-0.30	-0.30	-0.22	-0.23	-7.10%	-7.10%	-4.33%	-3.13%	-23.46%	-23.46%	-19.31%	-13.83%
	Equal Weight	-0.06	-0.06	-0.06	-0.06	-1.26%	-1.26%	-1.26%	-1.26%	-20.84%	-20.84%	-20.84%	-20.84%
	Benchmark (0050)	-0.09	-0.09	-0.09	-0.09	-1.96%	-1.96%	-1.96%	-1.96%	-21.08%	-21.08%	-21.08%	-21.08%

各核心指標勝出分布


📊 1. 總勝出次數排行榜 (已依 MVO → SA → QA20 → QA100 順序對齊)：

- 【MVO】 在所有戰場中一共勝出 4 次
- 【SA】 在所有戰場中一共勝出 6 次
- 【QA20】 在所有戰場中一共勝出 9 次
- 【QA100】 在所有戰場中一共勝出 17 次

🔍 2. 各核心指標下的勝出次數分布：

Winner_Algo	MVO	SA	QA20	QA100
Metric				
Calmar Ratio	0	2	4	6
Cumulative Return	0	2	3	7
Max Drawdown	4	2	2	4

總勝出排行





【GMVP 獨立戰場勝出統計】

1. 總勝出次數排行榜：

- 【MVO】 共勝出 4 次
- 【SA】 共勝出 4 次
- 【QA20】 共勝出 4 次
- 【QA100】 共勝出 6 次

2. 各指標下的勝出次數分佈：

Winner_Algo	MVO	SA	QA20	QA100
Metric				
Calmar Ratio	0	1	2	3
Cumulative Return	0	1	2	3
Max Drawdown	4	2	0	0

【MSRP 獨立戰場勝出統計】

1. 總勝出次數排行榜：

- 【MVO】 共勝出 0 次
- 【SA】 共勝出 2 次
- 【QA20】 共勝出 5 次
- 【QA100】 共勝出 11 次

2. 各指標下的勝出次數分佈：

Winner_Algo	MVO	SA	QA20	QA100
Metric				
Calmar Ratio	0	1	2	3
Cumulative Return	0	1	1	4
Max Drawdown	0	0	2	4



GMVP 戰場

MVO 橫掃最大回撤 (4 勝全勝)

連續精確度把風險壓到極致。

QA100 反而贏報酬與卡瑪比率

尋優不完全 + 強迫分散，誤打誤撞分配到帶攻擊性的股票，在此區間意外勝出。



MSRP 戰場

QA100 毀滅性統治：11 / 15 勝

MVO 0 勝、SA 2 勝。

為什麼？

① 風險趨避目標函數天生更保守；② 1% 顆粒度兼顧分散防禦與微調彈性，避開 MVO 的雜訊陷阱。



量子絕熱定理：理想與現實的斷層

絕熱定理保證「只要時間夠長，必收斂到最佳解」— 但為何實驗仍翻車、還要手調 *sweeps / reads* ?



你跑的是「假量子」

neal 的 SimulatedAnnealingSampler 本質是傳統 CPU 模擬退火，靠熱擾動而非量子隧道，根本不受絕熱定理庇護。



真量子也受物理限制

絕熱時間 $\tau \propto 1/\Delta_{\min}^2$ 。精度變細 $\rightarrow$ 能隙 $\Delta_{\min} \rightarrow 0 \rightarrow \tau$ 暴增到天文數字（數年甚至數百年）。



sweeps / reads 是逼近的閥

在傳統電腦上用人工算力模擬那段「無限久時間」：*sweeps* = 時間、*reads* = 多派探險隊取最佳生還者。

$$\tau \propto \frac{1}{\Delta_{\min}^2}$$

能隙坍塌 當 precision 從 20 $\rightarrow$ 100，無數次優解的能量與最優解極度接近，最小能隙 $\Delta_{\min}$ 趨近 0，絕熱所需時間呈指數暴增。這正是業界寄望真正 D-Wave QPU（量子隧道穿牆）的原因。

研究總結與核心洞察

Research Summary & Core Insights



01

過度擬合陷阱 vs 被動魯棒性

MVO 解析解是精確手術刀，輸入乾淨時鎖定全局最佳；但金融預測天生雜訊與非平穩，使其淪為「雜訊放大器」、極端重倉、樣本外過度擬合。QA 的離散化編碼限制極端權重、尋優不完全，意外形成天然的「正則化」保護，注入樣本外魯棒性。



02

尋優退化：解空間爆炸與運算瓶頸

Precision 100 偏誤反大於 Precision 20，並非理論失效，而是「尋優退化」。顆粒度變細使二元組合幾何級數暴增，平緩地形轉為「針狀地形」；受限傳統 CPU 模擬器與有限 sweeps，演算法極易凍結於局部次優解。離散精確度是一把雙面刃。



03

未來戰場：高維非凸地形與量子霸權

當前 50 檔仍處解析解舒適圈。一旦資產維度暴增、引入衍生品與換手率 / 基數 / 階梯成本等非線性約束，地形將轉為「非凸地形」，凸優化失效、面臨 NP-Hard 複雜度爆炸。此時 QA 與真量子 QPU 可藉量子隧道效應穿透能量山峰，展現量子霸權潛力。(目前文獻也缺少以量子退火解大量複雜資產的可靠與可行性分析)

核心洞察 極致擬合 ≠ 實盤贏家 — 在雜訊主導的真實市場，演算法的「被動正則化」才是生存法則。



附錄 · Appendix

業界實務的投資組合最佳化方法

為何「Softmax 排名 + GMVP 線性組合」優於直接組 MSRP



實務最佳化流程：排名 $\rightarrow$ Softmax $\rightarrow$ 線性組合

不直接輸出權重，而是讓模型預測「季報酬率排名」，再經多步轉換建構穩健投組。



為何要線性組合？ Softmax(模型 alpha) 提供進攻性、GMVP 提供風險分散；兩者融合兼顧 alpha 與穩健，避免單一來源的極端配置。



MSRP 的脆弱性

極度依賴輸入準確度

MSRP 同時吃「預期報酬」與「共變異」，權重好壞高度受輸入準確度左右。

病態的共變異矩陣

金融資產的 Σ 天生 condition number 很大；矩陣求逆時，輸入的微小誤差會被劇烈放大。

權重劇烈跳動

一點點報酬預測偏差，就足以讓 MSRP 算出的最佳權重大幅變動，甚至 All-in 單一資產。



線性組合的優勢

GMVP 不吃報酬預測

GMVP 只需共變異矩陣，避開最不可靠的「未來報酬預測」這一環。

Softmax 提供溫和 alpha

以排名（而非絕對數值）驅動權重，天然抑制極端值，比 MSRP 的硬最佳化更平滑。

兩者互補、抗雜訊

50% 模型 + 50% GMVP，在追逐 alpha 的同時保有分散防禦 — 實證上比直接組 MSRP 更穩健。